

Análisis Estadístico del Turismo Emisivo en Uruguay: Muestreo, Descriptiva e Inferencia a partir de Datos Abiertos

Facultad de Ingeniería y Tecnologías

Universidad Católica del Uruguay

Probabilidad y Estadística Aplicada — Tarea 2

Estudiantes:

Mateo Di Fortuna — Cédula: 5.531.922-6

Joaquín García — Cédula: - 5.567.618-7

Agustín Maldonado — Cédula: 5.221.742-7

Josué Merino — Cédula: 6.660.183-4

Docentes: Catarina García Luna, Candido Lucas De Oliveira Gaffrée

Montevideo, Uruguay

3 de julio de 2026

Resumen

En este trabajo se hace un análisis estadístico completo de los datos de turismo emisor del Uruguay, tomados del Catálogo Nacional de Datos Abiertos del Ministerio de Turismo. Se extrajo una muestra aleatoria equiprobable de 2.000 registros de un conjunto de 32.109 observaciones, garantizando representatividad y reproducibilidad con una semilla fija (42). El análisis descriptivo consistió en la clasificación de variables, tablas de frecuencias y gráficos de distribución para la variable Destino, tablas por intervalos, histograma y diagrama de cajas para la variable GastoAlojamiento y diagrama de dispersión entre Gente y GastoTotal. El análisis inferencial entendió intervalos de confianza al 95 % para las medias de las variables de gasto, pruebas de hipótesis (t-test para una muestra y para muestras emparejadas), un test de independencia Chi-cuadrado y un modelo de regresión lineal simple. Los resultados indican que Argentina y Brasil concentran el 85.6 % de los viajes, mientras que el gasto en alojamiento muestra una media de 315.81 USD con una marcada asimetría positiva (sesgo = 4.73). Se rechaza la hipótesis nula que indica que el gasto promedio en alojamiento es al menos 350 USD ($t = -2.69$, $p = 0.0036$), lo que muestra que los uruguayos gastan, en promedio, menos de ese monto. No hay evidencia suficiente para afirmar que el gasto en alimentación es mayor que el gasto en compras ($t = 1.18$, $p = 0.1183$). El test de Chi-cuadrado mostró dependencia entre la duración de la estadía y el lugar de salida ($\chi^2 = 481.53$, $p < 0.001$), aunque no se cumple plenamente el supuesto de

frecuencias esperadas mínimas. El modelo de regresión lineal estima un aumento en el gasto total de 339.56 USD por cada persona adicional en el grupo, pero el bajo coeficiente de determinación ($R^2 = 0.0756$) indica que la variable Gente explica solamente el 7.56 % de la variabilidad del gasto total.

Palabras clave: turismo emisor, estadística descriptiva, inferencia estadística, Python, análisis de datos.

1. Introducción

El turismo emisor, es decir, los viajes realizados por residentes de un país hacia el exterior, es un indicador económico y social de gran importancia para entender los patrones de consumo, las preferencias de destino y la estructura de gastos de la población. El Ministerio de Turismo uruguayo lleva un registro organizado de esos viajes a través de encuestas que se realizan en las fronteras, aeropuertos y puertos, lo que genera una importante base de datos que sirve para definir el perfil del viajero uruguayo.

El presente trabajo tiene como objetivo general realizar un análisis estadístico completo de datos de turismo emisor, desde la adquisición y muestreo de los datos hasta la inferencia sobre parámetros poblacionales. Los objetivos específicos son: (i) obtener una muestra aleatoria representativa de 2.000 registros; (ii) describir las principales variables mediante tablas y gráficos; (iii) estimar medias poblacionales de gasto mediante intervalos de confianza; (iv) contrastar hipótesis sobre el gasto en alojamiento y comparar gastos en alimentación y compras; (v) evaluar la independencia entre la duración de la estadía y el lugar de salida; y (vi) modelar la relación entre el tamaño del grupo y el gasto total mediante regresión lineal.

El análisis se realizó en Python 3.11 utilizando las librerías pandas, numpy, matplotlib, scipy y scikit-learn. El informe se organiza en las secciones de metodología, resultados y análisis, conclusiones, referencias y anexos, de acuerdo con las normas de la 7.^a edición del manual de estilo APA (American Psychological Association, 2020).

2. Marco Teórico

El muestreo aleatorio simple es una técnica de selección en la cual cada muestra posible de tamaño n posee la misma probabilidad de ser elegida. Este procedimiento permite obtener muestras representativas y realizar inferencias válidas sobre una población.

La estadística descriptiva comprende métodos destinados a organizar, resumir y representar datos mediante tablas, gráficos y medidas numéricas. Las medidas de tendencia central, dispersión y posición permiten describir el comportamiento de las variables observadas.

La inferencia estadística permite extraer conclusiones sobre parámetros poblacionales a partir de información muestral. Los intervalos de confianza proporcionan rangos plausibles para parámetros desconocidos, mientras que las pruebas de hipótesis permiten evaluar afirmaciones respecto a dichos parámetros mediante evidencia estadística.

La prueba Chi-cuadrado de independencia permite determinar si existe asociación entre dos variables categóricas. Por otro lado, la regresión lineal simple estudia la relación entre una variable predictora y una variable respuesta mediante un modelo lineal, permitiendo cuantificar y analizar dicha relación.

3. Metodología

3.1 Fuente de Datos

Los datos se obtuvieron del Catálogo de Datos Abiertos del Gobierno Uruguayo, del conjunto "Ministerio de Turismo — Turismo Emisivo", disponible en <https://catalogodatos.gub.uy/dataset/ministerio-de-turismo-turismo-emisivo> El archivo original (emisivo.csv) cuenta con 32.109 registros y 41 columnas, correspondientes a viajes realizados por residentes uruguayos entre los años 2016 y 2025. Las variables incluyen datos sobre el lugar de origen, destino, fechas de viaje, duración de la estancia, número de personas que conforman el grupo, gastos desagregados (alojamiento, alimentación, transporte, compras, entre otros) y características sociodemográficas del viajero.

3.2 Muestreo Aleatorio

Se utilizó muestreo aleatorio simple sin reposición, con lo que cada una de las 32.109 filas tuvo la misma probabilidad de ser elegida (equiprobabilidad). El muestreo se realizó mediante selección aleatoria simple sin reposición, donde todas las muestras posibles de tamaño 2.000 tienen igual probabilidad de ser seleccionadas. La probabilidad asociada a una muestra específica es: $P(\text{muestra}) = 1/C(32109, 2000)$. Se fijó la semilla aleatoria en 42 para asegurar la reproducibilidad.

El proceso se realizó en Python usando el método `.sample(n=TAMANIO_MUESTRA, replace=False, random_state=SEMILLA_ALEATORIA)` de la librería pandas. La muestra resultante se guardó en un archivo llamado `muestra_2000.csv`, que será la base de todo el análisis posterior.

3.3 Herramientas Computacionales

El análisis se llevó a cabo en Python 3.11 utilizando las siguientes librerías:

Tabla de herramientas computacionales

Librería	Versión	Propósito
<i>pandas</i>	2.2.2	Manipulación y análisis de datos tabulares
<i>numpy</i>	1.26.4	Operaciones numéricas
<i>matplotlib</i>	3.9.0	Generación de gráficos
<i>scipy</i>	1.13.1	Funciones estadísticas (tests t, Chi-cuadrado)
<i>scikit-learn</i>	1.5.0	Modelado de regresión lineal

3.4 Procedimiento Estadístico

El estudio se dividió en dos grandes bloques:

Estadística descriptiva:

- Clasificación de las variables según su tipo y escala de medición.
- Tabla de frecuencias absolutas y relativas para Destino
- Gráfico de barras y gráfico de círculo para Destino.
- Tabla de frecuencias por intervalos para GastoAlojamiento (regla de Sturges) con marcas de clase, frecuencias relativas y acumuladas.
- Histograma y diagrama de cajas (boxplot) para la variable GastoAlojamiento, cálculo de cuartiles, rango intercuartílico (IQR) y detección de outliers según el criterio de Tukey.
- Gente vs. GastoTotal: diagrama de dispersión y coeficiente de correlación de Pearson.

Inferencia estadística:

- Intervalos de confianza al 95 % para las medias de todas las variables de gasto, con base en la distribución t de Student.

- Test t de una muestra para comprobar si la media de GastoAlojamiento es menor de 350 USD (hipótesis unilateral izquierda).
- Test t para muestras apareadas para comparar la diferencia media entre GastoAlimentacion y GastoCompras (hipótesis unilateral derecha).
- Prueba de independencia de Chi-cuadrado entre Estadía (categorizada en corta, mediana y larga) y LugarSalida (agrupando categorías con menos de 30 observaciones en "Otros").
- Modelo de regresión lineal simple con gente como variable predictora y GastoTotal como variable respuesta, incluyendo estimación de parámetros, coeficiente de determinación y prueba de significancia de la pendiente.
- En todas las pruebas de hipótesis se utilizó un nivel de significación $\alpha = 0.05$.

4. Resultados y Análisis

4.1 Clasificación de Variables

La Tabla 1 presenta la clasificación de las seis variables solicitadas según su naturaleza y escala de medición.

Tabla 1

Clasificación de variables según tipo y escala

Variable	Tipo	Escala
LugarSalida	Cualitativa	Nominal
FechaSalida	Cualitativa	Ordinal
Destino	Cualitativa	Nominal
Estadía	Cuantitativa	Discreta
Gente	Cuantitativa	Discreta
GastosTotales	Cuantitativa	Continua

4.2 Tabla de Frecuencias de Destino

La Tabla 2 muestra la distribución de la variable Destino en la muestra de 2.000 viajes.

Tabla 2

Frecuencias de la variable Destino

Destino	Frec. absoluta	Frec. relativa (%)
Argentina	1283	64.15

Brasil	429	21.45
Centro y Norte América	86	4.30
Europa	66	3.30
Chile	48	2.40
Resto Sud América	38	1.90
Paraguay	33	1.65
África	6	0.30
Asia del Este y Pacífico	6	0.30
Oriente Medio	3	0.15
Sin Datos	1	0.05
Otros	1	0.05
Total	2000	100.00


Se observa una clara preponderancia de Argentina (64.15 %) y Brasil (21.45 %), que en conjunto representan el 85.60 % de los viajes. El resto de los destinos presenta frecuencias muy inferiores, lo que indica una fuerte concentración en países limítrofes.

4.3 Gráficos de Destino

La Figura 1 muestra el gráfico de barras y el gráfico circular para la variable Destino.

Figura 1

Distribución de viajes por destino



Nota. Las categorías con menos del 1 % de frecuencia se agruparon en "Otros" para mejorar la legibilidad del gráfico circular.

El gráfico de barras confirma la dominancia de Argentina y Brasil, el gráfico circular permite ver la pequeña proporción de otros destinos.

Conclusión de los resultados obtenidos: Los destinos muestran una marcada concentración en los países limítrofes, lo que indica que la mayoría de los viajes internacionales de los uruguayos son de corta distancia. Este patrón coincide con las características del turismo emisor en países sudamericanos, donde predominan los destinos regionales sobre los intercontinentales.

4.4 Tabla de Frecuencias por Intervalos de Gasto Alojamiento

Para el análisis de gasto se seleccionó la variable GastoAlojamiento por su relevancia para la hipótesis planteada en la Parte 3. Esta variable mide el gasto en alojamiento durante el viaje, expresado en dólares estadounidenses.

Para construir la tabla de intervalos se aplicó la regla de Sturges (1926), que recomienda un número de intervalos $k = 1 + \log_2(2000) \approx 12$. Con un ancho de 600 USD, se obtuvieron los intervalos presentados en la Tabla 3.

Tabla 3

Frecuencias por intervalos de Gasto Alojamiento

Intervalo	Marca de clase	Frec. abs.	Frec. rel.	Frec. acum.
[0.0, 600.0)	300.0	1676	0.8380	0.838
[600.0, 1200.0)	900.0	246	0.1230	0.961
[1200.0, 1800.0)	1500.0	37	0.0185	0.9795
[1800.0, 2400.0)	2100.0	12	0.0060	0.9855
[2400.0, 3000.0)	2700.0	4	0.0020	0.9875
[3000.0, 3600.0)	3300.0	10	0.0050	0.9925
[3600.0, 4200.0)	3900.0	7	0.0035	0.9960
[4200.0, 4800.0)	4500.0	4	0.0020	0.9980
[4800.0, 5400.0)	5100.0	2	0.0010	0.9990
[5400.0, 6000.0)	5700.0	0	0.0000	0.9990
[6000.0, 6600.0)	6300.0	2	0.0010	1.0000
[6600.0, 7200.0)	6900.0	0	0.0000	1.0000
Total	—	2000	1.0000	—

Nota. Regla de Sturges: $k = 12$ intervalos, ancho = 600 USD.


El 83.80 % de los viajes presenta un gasto en alojamiento inferior a 600 USD, y solo el 1.2 % supera los 1800 USD, lo que evidencia una fuerte concentración en valores bajos.

4.5 Histograma de GastoAlojamiento

La Figura 2 presenta el histograma de GastoAlojamiento junto con las líneas de la media y la mediana.

Figura 2

Histograma de GastoAlojamiento



Las medidas de tendencia central y de dispersión son: Mediana: 147.36 USD; Media: 315.81 USD; Asimetría (skewness): 4.7283.

Como la media (315.81) es bastante superior a la mediana (147.36) y la asimetría es positiva y alta, la distribución tiene una larga cola a la derecha, lo cual refleja que unos pocos

viajeros con gastos muy elevados elevan el promedio. Casi todos los viajeros se alojan en un hotel por menos de 150 USD.


Conclusión de la simetría: La distribución del gasto en alojamiento no es simétrica, tiene sesgo positivo (asimetría a la derecha). Este tipo de comportamiento es típico en variables económicas de gasto, donde la presencia de outliers tiende a desplazar la media a la parte alta.

4.6 Diagrama de Cajas (Boxplot) de GastoAlojamiento

La Figura 3 muestra el diagrama de cajas para GastoAlojamiento.

Figura 3

Boxplot de GastoAlojamiento



Los cuartiles y el rango intercuartílico (IQR) obtenidos fueron: Q1 (primer cuartil) = 0.00 USD, Q2 (mediana) = 147.36 USD, Q3 (tercer cuartil) = 408.98 USD e IQR = 408.98 USD. La presencia de una elevada cantidad de registros con gasto nulo en alojamiento puede explicar que el primer cuartil tome un valor igual a cero.

El límite superior de Tukey para la detección de valores atípicos es: $Q3 + 1.5 \times IQR = 408.98 + 613.47 = 1022.45$ USD. Se encontraron 110 outliers con gastos mayores a 1022.45 USD. Estos valores atípicos refuerzan la asimetría positiva que muestra el histograma.


Conclusión en cuanto a datos atípicos: La muestra muestra 110 casos atípicos en el gasto de alojamiento, lo que indica que hay un segmento de viajeros que gasta significativamente más que la media. Estos outliers podrían ser viajes de lujo, destinos caros o estancias largas.

4.7 Diagrama de Dispersión: Gente vs GastoTotal

La Figura 4 presenta el diagrama de dispersión entre las variables Gente y GastoTotal, junto con la línea de tendencia lineal.

Figura 4

Dispersión entre Gente y GastoTotal



El coeficiente de correlación de Pearson es de $r = 0,2750$. El bajo valor positivo señala que el número de personas que conforman el grupo está ligeramente relacionado con el gasto total. Aunque se observa una ligera tendencia al alza, la gran dispersión de los puntos indica que otros factores (destino, duración, tipo de alojamiento) influyen fuertemente en el gasto total.

Conclusión de dependencia: Hay una débil dependencia positiva entre el número de personas del grupo y el gasto total. Aunque viajar en grupo implica mayores costos totales, la correlación no es fuerte, lo que indica que otros factores también contribuyen de manera significativa.

4.8 Intervalos de Confianza para las Medias de Gasto

Se construyeron intervalos de confianza al 95 % para la media poblacional de cada una de las ocho variables de gasto disponibles. La Tabla 4 resume los resultados.

Tabla 4

Intervalos de confianza al 95 % para las medias de variables de gasto

Variable	Media	Desv. std.	Error std.	L. inferior	L. superior
GastoAlojamiento	315.81	568.09	12.70	290.89	340.72
GastoAlimentacion	265.67	329.52	7.37	251.22	280.12
GastoTransporteInternac	310.85	824.09	18.43	274.72	346.99
GatoTransporteLocal	137.27	235.50	5.27	126.95	147.60
GastoCultural	81.86	156.34	3.50	75.01	88.72
GastoTours	4.98	28.24	0.63	3.75	6.22
GastoCompras	253.62	470.25	10.52	233.00	274.24

GastoResto	111.25	259.06	5.79	99.89	122.61
------------	--------	--------	------	-------	--------

Nota. El intervalo se calcula como $\bar{x} \pm t(0.025, 1999) \cdot (s/\sqrt{n})$, con $t(0.025, 1999) \approx 1.9612$.

Interpretación de resultados: Los mayores gastos promedio corresponden a alojamiento y transporte internacional, cuyos intervalos presentan valores centrales superiores a los demás rubros. En cambio, gastos como tours y actividades culturales presentan valores promedio considerablemente menores. Esto sugiere que los principales componentes del gasto turístico se concentran en alojamiento y transporte.

4.9 Pruebas de Hipótesis

4.9.1 Test *t* para Gasto Alojamiento

Se contrastó la hipótesis de que el gasto medio en alojamiento es inferior a 350 USD.

- $H_0: \mu \geq 350$
- $H_1: \mu < 350$
- $\alpha = 0.05$
- Estadístico *t*: -2.6919
- p-valor (cola izquierda): 0.0036

Dado que $p = 0.0036 < 0.05$, se rechaza H_0 . Existe evidencia estadística suficiente para afirmar que, en promedio, los uruguayos gastan menos de 350 USD en alojamiento durante sus viajes internacionales.

4.9.2 Test *t* pareado: Alimentación vs Compras

Se evaluó si el gasto en alimentación es superior al gasto en compras.

- $H_0: \mu_{\text{alimentacion}} \leq \mu_{\text{compras}}$
- $H_1: \mu_{\text{alimentacion}} > \mu_{\text{compras}}$

- $\alpha = 0.05$
- Estadístico t: 1.1839
- p-valor (cola derecha): 0.1183

El p-valor es mayor que 0.05, por lo que no se rechaza H_0 . No hay evidencia suficiente para afirmar que los uruguayos gasten más en alimentación que en compras.

4.9.3 Test Chi-cuadrado de independencia

Se analizó la relación entre la duración de la estadía (categorizada en corta, mediana y larga) y el lugar de salida (agrupando categorías con menos de 30 observaciones en "Otros"). La Tabla 5 muestra la tabla de contingencia.

Tabla 5

Tabla de contingencia: Estadía vs LugarSalida

Estadía	Carr.	B.Unión	Chuy	Colonia	F.Bentos	Paysandú	Pto.Mvd	Rivera	R.Branco	Salto	Otros	Total
Corta (1-7 d)	196	22	48	322	278	205	86	49	28	207	61	1502
Mediana (8-14 d)	175	12	39	18	34	17	7	24	15	32	16	389
Larga (15+ d)	81	0	6	6	2	4	2	0	2	3	3	109
Total	452	34	93	346	314	226	95	73	45	242	80	2000

Los resultados del test fueron: Estadístico $\chi^2 = 481.5337$; Grados de libertad: 20; p-valor: 0.0000 (prácticamente cero); Frecuencia esperada mínima: 1.85 (menor a 5, lo que invalida parcialmente el supuesto).

A pesar de la advertencia sobre la frecuencia esperada mínima, el p-valor extremadamente bajo sugiere una fuerte dependencia entre la duración de la estadía y el lugar de salida. Se rechaza H_0 y se concluye que estas variables no son independientes.

4.10 Regresión Lineal Simple

Se ajustó un modelo de regresión lineal con Gente como variable predictora y GastoTotal como respuesta. La ecuación estimada es:

$$\widehat{GastoTotal} = 419.19 + 339.56 \cdot Gente$$


Interpretación de los parámetros: β_0 (intercepto) = 419.19 USD: valor estimado del gasto total cuando el número de personas es cero (sin interpretación práctica directa). β_1 (pendiente) = 339.56 USD por persona: por cada persona adicional en el grupo, el gasto total esperado aumenta en 339.56 USD.

El coeficiente de determinación obtenido fue $R^2 = 0.0756$, lo que indica que la variable Gente explica el 7.56 % de la variabilidad observada en GastoTotal. Esto sugiere que la cantidad de personas tiene una capacidad explicativa limitada sobre el gasto total. La prueba de significancia de la pendiente arrojó: $t = 12.7831$; $p\text{-valor} \approx 0.0000$.

Por lo tanto, la pendiente es significativamente distinta de cero, lo que indica una relación lineal estadísticamente significativa entre ambas variables. Sin embargo, el resultado sugiere que otras variables podrían contribuir de forma más importante a explicar el comportamiento del gasto total.

Figura 5

Regresión lineal: GastoTotal vs Gente



5. Conclusiones

El análisis estadístico realizado sobre los datos de turismo emisor del Uruguay ha permitido extraer conclusiones relevantes tanto desde el punto de vista descriptivo como inferencial.

El análisis estadístico realizado sobre los datos de turismo emisor del Uruguay permitió identificar patrones relevantes sobre el comportamiento de los viajeros y la estructura de sus gastos.

La distribución de destinos muestra una marcada concentración en Argentina y Brasil, que representan el 85.6 % de los viajes observados. Esto evidencia una fuerte preferencia por destinos regionales y cercanos geográficamente.

Los gastos presentan una importante heterogeneidad entre viajeros. En particular, el gasto en alojamiento exhibe una fuerte asimetría positiva, con presencia de valores atípicos que elevan la media respecto de la mediana. Asimismo, los mayores gastos promedio corresponden a alojamiento y transporte internacional.

Los resultados inferenciales indican evidencia suficiente para afirmar que el gasto promedio en alojamiento es inferior a 350 USD. Además, no se encontró evidencia estadística suficiente para concluir que el gasto en alimentación sea superior al gasto en compras.

Finalmente, se observó una relación positiva entre la cantidad de personas y el gasto total; sin embargo, la capacidad explicativa de esta relación es limitada, lo que sugiere que otras variables pueden desempeñar un papel importante en el comportamiento del gasto turístico.

6. Referencias

- American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7th ed.). <https://doi.org/10.1037/0000165-000>
- Gobierno de Uruguay. (s.f.). *Turismo emisoro*. Catálogo Nacional de Datos Abiertos. Recuperado el 29 de junio de 2026, de <https://catalogodatos.gub.uy/dataset/ministerio-de-turismo-turismo-emisoro>
- McKinney, W. (2022). *Python for data analysis* (3rd ed.). O'Reilly Media.
- Sturges, H. A. (1926). The choice of a class interval. *Journal of the American Statistical Association*, 21(153), 65–66. <https://doi.org/10.1080/01621459.1926.10502161>
- Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

7. Anexos

Anexo A: Script parte1_muestreo.py

El script de Python correspondiente a esta sección se adjunta de forma digital en la carpeta /codigo dentro del directorio raíz del proyecto, bajo el nombre parte1_muestreo.py.

Anexo B: Script parte2_descriptiva.py

El script de Python correspondiente a esta sección se adjunta de forma digital en la carpeta /codigo dentro del directorio raíz del proyecto, bajo el nombre parte2_descriptiva.py

Anexo C: Script parte3_inferencia.py

El script de Python correspondiente a esta sección se adjunta de forma digital en la carpeta /codigo dentro del directorio raíz del proyecto, bajo el nombre parte3_inferencia.py

Anexo D: Archivo muestra_2000.csv

El conjunto de datos original utilizado en este trabajo se adjunta de forma digital en la carpeta /datos dentro del directorio raíz del proyecto, bajo el nombre muestra_2000.csv.

Lista de Tablas

Tabla 1 — Clasificación de variables según tipo y escala de medición

Tabla 2 — Frecuencias de la variable Destino

Tabla 3 — Frecuencias por intervalos de GastoAlojamiento

Tabla 4 — Intervalos de confianza al 95 % para las medias de variables de gasto

Tabla 5 — Tabla de contingencia: Estadía vs LugarSalida

Lista de Figuras

Figura 1 — Distribución de viajes por destino

Figura 2 — Histograma de GastoAlojamiento

Figura 3 — Boxplot de GastoAlojamiento

Figura 4 — Dispersión entre Gente y GastoTotal

Figura 5 — Regresión lineal: GastoTotal vs Gente